Background & Motivation

Project ini disusun sebagai bagian dari upaya pengembangan kemampuan dalam eksplorasi dan analisis data menggunakan SQL, khususnya dalam konteks data e-commerce yang kompleks dan berskala besar.

Sebagai salah satu bahasa utama dalam *data analytics*, SQL tidak hanya digunakan untuk mengambil data, tetapi juga untuk membangun logika analisis, melakukan agregasi, serta menghasilkan insight yang relevan dengan kebutuhan bisnis. Oleh karena itu, project ini dirancang sebagai latihan terstruktur untuk:

- Mengasah kemampuan query SQL secara end-to-end
- Memahami struktur dan relasi antar tabel dalam dataset nyata
- Menerjemahkan kebutuhan bisnis menjadi analisis berbasis data

Dataset **bigquery-public-data.thelook_ecommerce** dipilih karena mampu merepresentasikan skenario e-commerce yang realistis, khususnya dalam hal struktur data transaksi, relasi antar entitas, serta kompleksitas yang umum ditemui dalam analisis revenue.

Selain sebagai sarana pembelajaran, project ini juga berfungsi sebagai **portfolio** yang mendemonstrasikan kemampuan dalam:

- Data exploration
- Analytical thinking
- Business-oriented data analysis

Project Overview

Dalam konteks analisis e-commerce, memahami hubungan antara transaksi, produk, dan pelanggan merupakan fondasi utama dalam menghasilkan insight yang bernilai. Project ini memanfaatkan dataset publik **bigquery-public-data.thelook_ecommerce**, yang merepresentasikan ekosistem operasional sebuah platform e-commerce secara end-to-end.

Dataset ini terdiri dari beberapa tabel utama, antara lain:

- orders dan order_items (data transaksi)
- products (informasi produk)
- users (profil pelanggan)
- inventory_items, distribution_centers, dan events (operasional dan aktivitas pengguna)

Namun, tidak seluruh tabel digunakan dalam analisis ini. Fokus eksplorasi diarahkan pada tiga tabel inti:

- **order_items** → sebagai sumber utama data transaksi granular (revenue, quantity, order behavior)
- **products** → untuk atribut produk (kategori, nama produk, dll.)
- **users** → untuk informasi pelanggan (demografi, lokasi, identitas user)

Pemilihan tabel ini didasarkan pada kebutuhan untuk membangun *analytical layer* yang cukup representatif tanpa menambah kompleksitas yang tidak relevan. Secara konseptual:

- order_items berperan sebagai **fact table** yang menyimpan metrik utama seperti revenue dan transaksi
- products dan users berfungsi sebagai **dimension tables** yang memberikan konteks tambahan terhadap transaksi

Relasi utama yang digunakan:

- order_items.product_id → products.id
- order_items.user_id → users.id

Pendekatan ini memungkinkan analisis dilakukan secara efisien dengan tetap mempertahankan granularitas data yang diperlukan untuk berbagai perspektif bisnis (produk, pelanggan, dan waktu).

Kenapa gak pake tabel yang lain?

Tabel lain seperti events, inventory_items, dan distribution_centers tidak digunakan dalam lingkup analisis ini karena:

- **events** lebih relevan untuk *behavioral analysis* (clickstream, funnel conversion), bukan revenue-focused analysis
- **inventory_items** dan **distribution_centers** lebih cocok untuk analisis operasional seperti supply chain dan inventory management

Dengan demikian, pembatasan scope ini merupakan keputusan yang disengaja untuk menjaga fokus pada **transactional analytics dan business performance metrics**.

3. Customer Segmentation

Melalui agregasi transaksi per user dari order_items yang di-*join* dengan users, pelanggan diklasifikasikan menjadi:

- **High-value customers**
- **Low-value customers**

Segmentasi ini memberikan gambaran distribusi kontribusi revenue serta membuka peluang untuk strategi retensi dan personalisasi.

Objective

Project ini bertujuan untuk:

- Membangun pemahaman terstruktur terhadap data e-commerce

- Menghasilkan insight berbasis SQL yang relevan untuk pengambilan keputusan
- Menunjukkan kemampuan dalam data modeling, query optimization, dan business-oriented analysis

Dengan pendekatan yang terfokus namun tetap komprehensif, hasil eksplorasi ini diharapkan mampu memberikan gambaran yang jelas mengenai performa bisnis dari berbagai dimensi, baik itu waktu, produk, pelanggan, dan wilayah serta menjadi fondasi untuk analisis lanjutan yang lebih kompleks.

Scope of Analysis

Dengan fondasi data tersebut, analisis difokuskan pada lima domain utama:

A. Revenue Trend (Monthly Growth + Growth Rate)

Menggunakan data transaksi dari order_items, kemudian dilakukan agregasi revenue secara bulanan untuk mengidentifikasi:

- Tren pertumbuhan pendapatan (*monthly growth*)
- Laju pertumbuhan (*growth rate*)

Analisis ini berfungsi sebagai indikator utama performa bisnis dari waktu ke waktu.

Query:

```
WITH monthly_revenue AS(
SELECT
  FORMAT_DATE('%Y-%m', Date(created_at)) AS month,
  SUM(sale_price) AS revenue
FROM bigquery-public-data.thelook_ecommerce.order_items
GROUP BY month
)

SELECT
  month,
  revenue,
  Lag(revenue) OVER (ORDER BY month) AS prev_revenue
FROM monthly_revenue
ORDER BY month
```

Output:

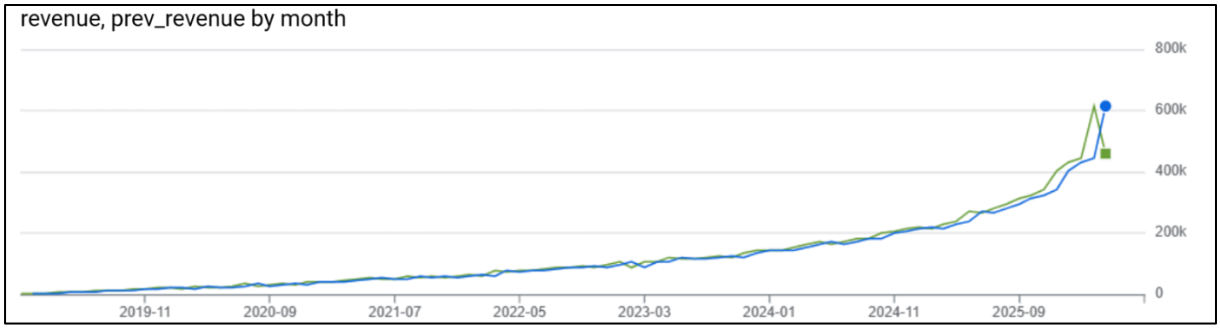

Insight:

Secara keseluruhan, revenue menunjukkan **tren naik yang konsisten** dari 2019 hingga 2025. Polanya bukan linear, tapi **eksponensial (accelerating growth)** terutama mulai sekitar **2023–2025**. Ini memiliki indikas ada **scaling effect** (misalnya: user base bertambah, repeat purchase meningkat) atau ada **perubahan strategi bisnis signifikan** (pricing, marketing, channel).

Jika dilihat dari visualisasi di atas, fase pertumbuhan bisa dibagi menjadi 3:

1. 2019 – 2021: Early Growth (Slow & Stable)
   Revenue naik perlahan namun variasinya masih kecil, artinya bisnis masih dalam fase stabilisasi. Adanya kemungkinan juga kalo growth didorong oleh **organic demand / baseline acquisition.**
2. 2022 – mid 2023: Acceleration Phase
   Slope mulai meningkat dan revenue growth lebih cepat dibanding periode sebelumnya. Hal ini bisa bertand kemungkinan ada **improvement di conversion rate** atau mulai efektifnya **campaign / channel acquisition**
3. Late 2023 – 2025: Hyper Growth + Volatility
   Kenaikan sangat tajam hingga mulai muncul **fluktuasi (spike & dip kecil).** Ini biasanya karena volume transaksi tinggi sehingga lebih sensitif terhadap perubahan dan ada faktor eksternal (promo besar, seasonality, campaign).

B. Product Performance (Top & Worst Product)

Dengan menggabungkan order_items dan products, dilakukan evaluasi performa produk untuk:

- Mengidentifikasi produk dengan kontribusi revenue tertinggi (*top performers*)
- Menemukan produk dengan performa rendah (*underperformers*)

Insight ini relevan untuk strategi optimasi katalog dan penentuan prioritas bisnis.

Query:

```
SELECT
  p.name AS product_name,
```

```sql
  SUM(oi.sale_price) AS total_revenue,
  COUNT(*) AS total_orders
FROM
  bigquery-public-data.thelook_ecommerce.order_items oi
JOIN
  bigquery-public-data.thelook_ecommerce.products p
ON
  oi.product_id = p.id
GROUP BY product_name
ORDER BY total_revenue DESC
LIMIT 10
```

Output:

10 Terbaik

product_name	total_revenue	total_order
The North Face Apex Bionic Soft Shell Jacket - Men's	23478.0	26
NIKE WOMEN'S PRO COMPRESSION SPORTS BRA *Outstanding Support and Comfort*	18060.0	20
The North Face Denali Down Womens Jacket 2013	14448.0	16
Canada Goose Men's The Chateau Jacket	12225.0	15
Jordan Low Quarter Sock Style #427411	9933.0	11
Woolrich Arctic Parka DF	9900.0	10
AIR JORDAN DOMINATE SHORTS MENS 465071-100	9030.0	10
Arc'teryx Men's Alpha SV Jacket	8750.0	14
True Religion Men's Ricky Straight Jean	8538.8	36
Canada Goose Women's Solaris	8340.0	12

10 terburuk

product_name	total_revenue	total_orders
Indestructable Aluminum Aluma Wallet - RED	0.099999997764825516	5
Set of 2 - Replacement Insert For Checkbook Wallets Card Or Picture Insert	1.4700000286102293	3
Individual Bra Extenders	1.75	1
Pink Ribbon Breast Cancer Awareness Relay for Life Knee Socks Great for Fundraising Walk Survivor (Style 05)	2.9500000476837158	1
Loravicci Womens Pink Short W/Draw String	4.9899997711181641	1
Black Belt for Buckle	5.3299999237060556	1
Designer Bow Ties for Men & Boys by Tok Tok Designs (Y166)	5.9000000953674316	2
Alivila.Y Fashion Sexy Lace Long Sleeve Lingerie Sleepwear Sleep Dress Set With G-String 481	5.9800000190734863	2
Angelina Arm Warmer / Sleeves Extension	5.9899997711181641	1

Allegra K Woman Faux Crystal Detail Leopard Print Strapped Tank Top M	6.96999979019165	1

Insight:

Analisis performa produk menunjukkan bahwa revenue sangat terkonsentrasi pada produk-produk premium, terutama kategori outerwear seperti jacket dari brand besar. Produk-produk ini menghasilkan kontribusi revenue yang tinggi meskipun jumlah order relatif kecil, yang mengindikasikan bahwa **average order value (AOV)** menjadi driver utama, bukan volume transaksi. Di sisi lain, terdapat produk dengan jumlah order cukup tinggi namun kontribusi revenue lebih rendah, menandakan adanya coexistence antara dua model bisnis, high-value low-volume dan low-value high-volume.

Kategori outerwear tampak sebagai kontributor utama revenue dan kemungkinan besar menjadi pendorong lonjakan pertumbuhan yang terlihat pada analisis tren sebelumnya. Dominasi brand ternama juga menunjukkan bahwa perilaku customer cenderung brand-driven, dengan willingness to pay yang tinggi terhadap produk tertentu. Sebaliknya, produk dengan performa terburuk memiliki revenue yang sangat kecil meskipun tetap mencatat order, yang mengindikasikan potensi masalah pada pricing strategy, value proposition, atau bahkan kualitas data (misalnya anomali harga atau diskon ekstrem).

Secara keseluruhan, distribusi revenue mengikuti pola long-tail, di mana sebagian kecil produk menyumbang mayoritas revenue, sementara sebagian besar produk lainnya memberikan kontribusi minimal. Hal ini membuka peluang untuk mengoptimalkan strategi dengan memfokuskan sumber daya pada produk high-performing, sekaligus mengevaluasi atau merasionalisasi produk dengan kontribusi rendah agar lebih efisien secara bisnis.

C. Customer Segmentation (High vs Low Value)

Melalui agregasi transaksi per user dari order_items yang di-*join* dengan users, pelanggan diklasifikasikan menjadi:

- **High-value customers**
- **Low-value customers**

Segmentasi ini memberikan gambaran distribusi kontribusi revenue serta membuka peluang untuk strategi retensi dan personalisasi.

Query:

```
WITH customer_revenue AS (
  SELECT
    user_id,
    SUM(sale_price) AS total_spent
  FROM
  bigquery-public-data.thelook_ecommerce.order_items
  GROUP BY user_id
```

```
)

SELECT
  CASE
    WHEN total_spent > 500 THEN 'High Value'
    WHEN total_spent BETWEEN 200 AND 500 THEN 'Mid Value'
    ELSE 'Low Value'
  END AS segment,
  COUNT(*) AS total_customers,
  AVG(total_spent) AS avg_spent
FROM customer_revenue
GROUP BY segment
```

Output:

segment	total_customers	avg_spent
Mid Value	15211	297.8201474344973
Low Value	62778	77.789648400895118
High Value	2074	675.91875136990609

Insight:

Segmentasi customer menunjukkan distribusi yang sangat timpang antara jumlah pelanggan dan kontribusi nilainya. Mayoritas customer berada di segmen **Low Value** (±62K user) dengan rata-rata spend yang rendah (~78), yang mengindikasikan bahwa sebagian besar user hanya melakukan pembelian kecil atau tidak repeat secara signifikan. Ini tipikal pola e-commerce di mana akuisisi besar tidak selalu diikuti monetisasi yang kuat.

Sebaliknya, segmen **High Value** jumlahnya sangat kecil (±2K user), namun memiliki rata-rata spend yang jauh lebih tinggi (~676). Ini menunjukkan adanya kelompok customer yang sangat bernilai, kemungkinan besar memiliki karakteristik seperti frekuensi pembelian tinggi, pembelian produk premium, atau loyalitas terhadap brand tertentu. Walaupun secara volume kecil, segmen ini berpotensi menyumbang porsi revenue yang signifikan bahkan bisa menjadi core driver dari total revenue.

Segmen **Mid Value** berada di tengah (±15K user, avg ~298) dan berperan sebagai "jembatan" antara low dan high value. Segmen ini penting karena secara strategis paling feasible untuk di-upgrade ke high value melalui intervensi seperti upselling, bundling, atau loyalty program.

Jika dikaitkan dengan analisis sebelumnya, kemungkinan besar pertumbuhan revenue yang accelerating didorong oleh kombinasi dua hal, peningkatan kontribusi dari high-value customers dan pergeseran sebagian mid-value customers ke tier yang lebih tinggi. Sementara itu, segmen low-value cenderung hanya berkontribusi pada volume, bukan nilai.

Implikasi bisnisnya cukup jelas, bahwa strategi tidak boleh hanya fokus pada akuisisi, tetapi harus menekankan **customer value expansion**. Segmen high-value perlu dipertahankan melalui retention strategy (loyalty, exclusivity, personalized offers), sementara segmen mid-

value menjadi target utama untuk ditingkatkan nilainya. Di sisi lain, segmen low-value perlu dioptimalkan secara efisien, baik melalui automation marketing atau strategi konversi yang scalable agar tidak menjadi beban biaya tanpa kontribusi revenue yang sepadan.

D. Regional Revenue Analysis

Dengan memanfaatkan atribut lokasi pada tabel users, analisis dilakukan untuk:

- Mengukur distribusi revenue berdasarkan wilayah
- Mengidentifikasi market dengan performa tinggi maupun rendah

Pendekatan ini membantu dalam memahami dinamika geografis dari bisnis.

Query:

```
SELECT
  u.country,
  SUM(oi.sale_price) AS total_revenue,
  COUNT(*) AS total_orders
FROM
  bigquery-public-data.thelook_ecommerce.order_items AS oi
JOIN
  bigquery-public-data.thelook_ecommerce.users AS u
ON oi.user_id = u.id
GROUP BY u.country
ORDER BY total_revenue DESC
```

Output:

country	total_revenue	total_orders
China	3645919.5	61050
United States	2425898.3	40787
Brasil	1609841.7	26816
South Korea	568032.5	9717
France	538826.1	8938
United Kingdom	476812.9	8092
Germany	446030.7	7531
Spain	437849.0	7375
Japan	262751.0	4534
Australia	244050.9	4052
Belgium	130570.5	2235
Poland	26963.9	432
Colombia	1245.7	18
Austria	649.8	9
España	34.0	1

Insight:

Analisis regional menunjukkan bahwa revenue sangat terkonsentrasi pada beberapa negara utama dengan **China** sebagai kontributor terbesar baik dari sisi revenue (~3.6M) maupun jumlah order (~61K), diikuti oleh **United States** dan **Brasil**. Pola ini mengindikasikan bahwa performa bisnis sangat bergantung pada market besar dengan volume tinggi, di mana skala populasi dan aktivitas transaksi menjadi driver utama pertumbuhan.

Menariknya, negara-negara seperti China dan Brasil tampak mengandalkan **volume transaksi tinggi**, sementara negara-negara di Eropa (UK, France, Germany, Spain) menunjukkan kontribusi revenue yang relatif seimbang dengan jumlah order yang lebih rendah. Ini mengarah pada indikasi bahwa **average order value (AOV)** di Eropa kemungkinan lebih tinggi atau lebih stabil dibanding market dengan volume besar. Dengan kata lain, ada perbedaan karakteristik market: beberapa bersifat **volume-driven**, sementara lainnya lebih **value-driven**.

Selain itu, terlihat adanya **long tail pada regional performance**, di mana banyak negara hanya memberikan kontribusi sangat kecil terhadap revenue. Bahkan terdapat anomali seperti duplikasi negara (misalnya "Spain" dan "España") yang mengindikasikan adanya **data quality issue** pada field country. Hal ini penting karena bisa menyebabkan distorsi dalam pengambilan keputusan berbasis wilayah.

Jika dikaitkan dengan analisis sebelumnya, kemungkinan besar lonjakan revenue secara global didorong oleh performa kuat dari negara-negara utama, khususnya China dan United States. Artinya, pertumbuhan bisnis tidak merata secara geografis, melainkan terkonsentrasi pada market tertentu yang sudah mature atau memiliki demand tinggi.

Secara strategis, perusahaan perlu mengadopsi pendekatan yang berbeda per region: mempertahankan dan mengoptimalkan market besar (seperti China dan US) sebagai **core revenue driver**, sambil mengeksplorasi peningkatan value di market menengah (Eropa, Korea, Jepang) melalui strategi pricing atau product mix. Untuk market kecil, perlu evaluasi apakah layak untuk dikembangkan lebih lanjut atau cukup dipertahankan secara efisien. Di sisi lain, perbaikan data standardization (misalnya normalisasi nama negara) menjadi krusial agar analisis regional lebih akurat dan dapat diandalkan.

E. Repeat vs New Customer (Retention Insight)

Menggunakan histori transaksi dalam order_items, dilakukan identifikasi:

- Pelanggan baru (*new customers*)
- Pelanggan yang melakukan pembelian ulang (*repeat customers*)

Analisis ini menjadi proxy untuk mengukur tingkat retensi dan loyalitas pelanggan.

Query:

```sql
WITH user_orders AS (
  SELECT
    user_id,
    COUNT(DISTINCT order_id) AS total_orders
  FROM
    bigquery-public-data.thelook_ecommerce.order_items
  GROUP BY user_id
)
SELECT
  CASE
    WHEN total_orders = 1 THEN 'one time'
    ELSE 'repeat'
  END AS customer_type,
  COUNT(*) AS total_users
FROM
  user_orders
GROUP BY customer_type
```

Output:

customer_type	total_users
repeat	29983
one time	50080

Insight:

Analisis repeat vs new customer menunjukkan bahwa mayoritas user adalah **one-time buyers** (±49K), sementara **repeat customers** hanya sekitar ±30K. Ini mengindikasikan bahwa meskipun bisnis berhasil menarik banyak customer baru, tingkat retensinya masih relatif rendah—lebih banyak user yang tidak kembali setelah pembelian pertama.

Dari perspektif bisnis, ini adalah sinyal bahwa model saat ini masih **acquisition-heavy, retention-light**. Artinya, pertumbuhan kemungkinan besar didorong oleh masuknya customer baru, bukan dari optimalisasi lifetime value (LTV). Padahal, berdasarkan teori e-commerce, repeat customer biasanya memiliki kontribusi revenue yang lebih tinggi karena mereka cenderung membeli lebih sering, lebih percaya pada brand, dan memiliki biaya akuisisi yang lebih rendah.

Jika dikaitkan dengan segmentasi sebelumnya, besar kemungkinan bahwa segmen **high-value customers** didominasi oleh repeat users. Dengan kata lain, meskipun jumlah repeat customer lebih kecil, mereka berpotensi menjadi kontributor utama revenue. Sebaliknya, one-time buyers kemungkinan besar mendominasi segmen low-value dengan kontribusi yang lebih kecil per user.

Implikasi strategisnya cukup krusial: peluang terbesar bukan hanya menambah customer baru, tetapi **mengkonversi one-time buyers menjadi repeat customers**. Ini bisa dilakukan melalui berbagai pendekatan seperti loyalty program, personalized marketing, post-purchase engagement, hingga strategi CRM berbasis data. Selain itu, penting juga untuk

mengidentifikasi titik drop-off dalam customer journey—mengapa sebagian besar user tidak kembali—apakah karena pengalaman, harga, kompetisi, atau faktor lain.

Secara keseluruhan, meningkatkan retention rate akan memberikan leverage yang jauh lebih besar terhadap revenue dibanding hanya meningkatkan acquisition, karena akan langsung berdampak pada peningkatan customer lifetime value dan stabilitas pertumbuhan bisnis.

Kesimpulan

Berdasarkan analisis yang dilakukan menggunakan dataset **bigquery-public-data.thelook_ecommerce**, dapat disimpulkan bahwa performa bisnis e-commerce dalam studi ini menunjukkan **pertumbuhan revenue yang kuat dan cenderung akseleratif**, terutama pada periode 2023–2025. Pertumbuhan ini tidak bersifat merata, melainkan didorong oleh kombinasi peningkatan kontribusi dari **produk bernilai tinggi**, **segmen customer ber-value besar**, serta **market geografis utama**.

Dari sisi **produk**, revenue sangat terkonsentrasi pada sejumlah kecil produk premium—khususnya kategori outerwear dari brand ternama. Pola ini mengindikasikan bahwa **average order value (AOV)** menjadi faktor utama pendorong pendapatan, bukan volume transaksi semata. Distribusi revenue yang bersifat *long-tail* menunjukkan bahwa sebagian besar produk memiliki kontribusi minimal, sehingga membuka peluang untuk optimasi katalog dan rasionalisasi produk dengan performa rendah.

Dari perspektif **customer**, segmentasi memperlihatkan ketimpangan yang jelas antara jumlah pelanggan dan nilai kontribusinya. Walaupun mayoritas user berada di segmen **Low Value**, sebagian kecil **High Value customers** berpotensi menyumbang porsi revenue yang signifikan. Segmen **Mid Value** menjadi target strategis untuk ditingkatkan nilainya melalui intervensi seperti upselling, bundling, dan loyalty program. Temuan ini menegaskan pentingnya pendekatan **customer value expansion**, bukan sekadar fokus pada akuisisi.

Analisis **retention** memperkuat kesimpulan tersebut, di mana proporsi **one-time buyers** lebih besar dibanding repeat customers. Hal ini mengindikasikan bahwa model pertumbuhan saat ini masih cenderung **acquisition-driven**, dengan ruang perbaikan yang besar pada strategi retensi dan peningkatan **customer lifetime value (LTV)**. Meningkatkan konversi pembeli sekali menjadi repeat customer berpotensi memberikan dampak yang jauh lebih besar dan berkelanjutan terhadap revenue.

Sementara itu, dari sisi **regional**, revenue global sangat terkonsentrasi pada beberapa negara utama seperti China, United States, dan Brasil. Namun, terdapat perbedaan karakteristik antar market, di mana sebagian bersifat **volume-driven** dan sebagian lainnya **value-driven**. Selain itu, ditemukannya isu kualitas data (seperti inkonsistensi penamaan negara) menunjukkan

pentingnya data standardization untuk memastikan akurasi analisis dan pengambilan keputusan.

Secara keseluruhan, project ini menunjukkan bahwa analisis SQL yang terstruktur mampu mengungkap **pola bisnis inti**, mulai dari tren pertumbuhan, driver revenue, hingga peluang strategis. Insight yang dihasilkan menegaskan bahwa keberlanjutan pertumbuhan bisnis e-commerce tidak hanya bergantung pada peningkatan transaksi, tetapi pada kemampuan untuk **mengoptimalkan produk unggulan, mempertahankan customer bernilai tinggi, dan meningkatkan retensi secara konsisten**.

Dengan demikian, analisis ini tidak hanya berfungsi sebagai latihan teknis SQL, tetapi juga sebagai fondasi yang kuat untuk pengambilan keputusan bisnis berbasis data dan analisis lanjutan yang lebih mendalam.